Guía de datos y entrenamiento

Centinelas de Santander · Qué datos usamos, cómo los limpiamos y cómo se entrenó cada modelo, explicado en palabras simples y con el detalle técnico al lado

3	184.723	4	0
modelos de aprendizaje supervisado	sismos en el catálogo del SGC	fuentes oficiales: SGC, USGS, DANE y UNGRD	sismos perdidos en la limpieza

---

UTSmart IA Challenge 2027 · Categoría Básica · Riesgo sísmico por zona en Los Santos, Santander
Santiago Steven Arias Estupiñán · Duván Andrés Palacio Figueredo · Camilo Andrés Bueno Rey
13 de octubre de 2026

Cómo leer esta guía

Esta guía acompaña al documento técnico. Aquel es formal; esta es para entender y poder explicar. Cada tema tiene dos recuadros:

EN PALABRAS SIMPLES
La idea contada como se la contarías a alguien que no sabe de programación ni de sismos.

TÉCNICAMENTE
El mismo punto con sus números, sus nombres y el archivo donde está.

OJO
Los recuadros amarillos marcan los límites y las cosas que el jurado puede preguntar.

El proyecto en un minuto

Los Santos está encima del **Nido Sísmico de Bucaramanga**: una zona, a unos 150 km bajo tierra, donde tiembla todos los días. Tomamos el registro oficial de sismos del Servicio Geológico Colombiano (SGC) y entrenamos un modelo que dice, para cada pedazo de 5,5 km de Los Santos, si el próximo trimestre tendrá actividad sísmica **baja, media o alta**.

Alrededor de ese modelo principal hay dos más y un simulador:

Pieza	Qué responde	Con qué datos aprende	Resultado
Modelo 1 · Sismos de Los Santos	**¿Qué zonas de Los Santos estarán más activas?**	**Catálogo del SGC**	**80,7 % de exactitud**
Modelo 2 · Sismos de Santander	Lo mismo, para todo el departamento	Catálogo del SGC	93,4 % de exactitud
Simulador de sacudida	Si tiembla con tal magnitud, ¿qué tan fuerte se siente en cada lugar?	Fórmulas publicadas + reportes del USGS	82 % acierta a ±1 grado
Modelo 3 · Viviendas y costo	¿Cuántas viviendas se afectarían y cuánto cuesta atenderlas?	Emergencias de la UNGRD + DANE + USGS	Orden de magnitud, con rango

Contenido

1. **Los datos, uno por uno:** de dónde sale cada conjunto, qué trae y para qué se usa.
2. **La limpieza del catálogo:** los cinco pasos y qué se hizo con lo que faltaba.
3. **Las tres decisiones sobre los datos:** magnitud 2,5, desde 2010 y catálogo de todo Santander.
4. **Entrenamiento 1:** sismos de Los Santos.
5. **Entrenamiento 2:** sismos de Santander.
6. **El simulador de sacudida.**
7. **Entrenamiento 3:** viviendas afectadas y costo.
8. **Preguntas que puede hacer el jurado,** con respuestas cortas, y un glosario.

1 Los datos, uno por uno

Todo viene de fuentes oficiales o de acceso abierto que el reto admite. Los archivos originales están en `entrenamiento/data/raw` y **nunca se modifican**: se leen, se limpian en memoria y el resultado se guarda aparte.

Cada ficha lleva una etiqueta: entrena si un modelo aprende de él, valida si sirve para comprobar, apoyo si solo se usa para mostrar, y no se usó si se descargó, se evaluó y se descartó.

1.1 Catálogo de sismicidad del SGC · todo Santander

entrena los modelos 1 y 2

EN PALABRAS SIMPLES

Es la lista oficial de todos los temblores que el Servicio Geológico Colombiano ha registrado en Santander desde 2006: uno por fila, con su fecha, dónde fue, a qué profundidad y qué tan fuerte. **Es el único dato con el que aprenden los dos clasificadores.**

Entidad	Servicio Geológico Colombiano, Red Sismológica Nacional
Filtros de descarga	Departamento: Santander · Municipio: todos · Fechas: 01/01/2006 a la fecha de descarga · Formato: CSV
Fecha de descarga	13 de octubre de 2026
Archivo	`data/raw/Santander - 01-01-2006 - 13-10-2026.csv` (30 MB)
Tamaño	184.723 sismos, 18 columnas. Del 1 de enero de 2006 al 9 de octubre de 2026
Qué trae	Identificador, fecha y hora, magnitud, profundidad, latitud, longitud, municipio, y medidas de calidad de la localización (`rms` , `gap` , número de estaciones, errores)

TÉCNICAMENTE

Magnitudes de −1,3 a 6,4 (media 1,86). Profundidad media de 135 km: casi todo ocurre entre 130 y 160 km, que es el nido. De las 19 columnas del catálogo limpio (las 18 originales más la energía), el modelo usa 6. Su limpieza se explica completa en la sección 2.

1.2 Catálogo del SGC · solo Los Santos

simulador

Es el mismo catálogo, pero filtrado por el **municipio** de Los Santos: 103.546 sismos (descarga del 12/10/2026, formato GeoJSON). Fue el catálogo del primer modelo. Lo reemplazamos porque dejaba fuera sismos de nuestra propia zona (sección 3.3). Hoy solo lo usa el simulador, para ubicar el centro del nido y calcular cada cuánto ocurren los sismos fuertes.

1.3 Intensidades «Did You Feel It?» del USGS

calibra y valida el simulador

EN PALABRAS SIMPLES

Cuando tiembla, el Servicio Geológico de Estados Unidos (USGS) le pregunta a la gente por internet: «¿lo sintió?, ¿qué tan fuerte?». Con esas respuestas arma un mapa de qué tan fuerte se sintió en cada lugar. Es lo más parecido que hay a una **medida real de la sacudida**, y el catálogo del SGC no la trae.

Filtros de descarga	Sismos de 2006 a 2026, a menos de 60 km del punto 6,80° N, 73,13° O (el nido), con profundidad mayor de 100 km y magnitud 4,5 o mayor
Fecha de descarga	12 de octubre de 2026 (`comun/src/descargar_intensidades_usgs.py`)
Tamaño	598 observaciones (lugares) de 86 sismos, que reúnen 1.831 respuestas de personas
Qué trae cada fila	El sismo (magnitud, profundidad, epicentro), el lugar del reporte (latitud y longitud), la intensidad reportada (`intensidad_cdi`) y cuántas personas respondieron allí
Limpieza	Llega sin faltantes ni repetidos. Se le añaden la distancia de cada lugar al sismo y la intensidad que da la fórmula física, para comparar

OJO

Son encuestas voluntarias: responde más la gente que sí lo sintió, y casi todas las respuestas vienen de ciudades grandes (Bogotá, Medellín, Bucaramanga). Ninguna observación pasa de intensidad VI, así que el nivel «Alto» de sacudida no se pudo comprobar con datos.

1.4 Emergencias de la UNGRD

entrena el modelo 3

EN PALABRAS SIMPLES

La Unidad Nacional para la Gestión del Riesgo lleva un registro de cada emergencia del país: un incendio, una inundación, un sismo. Para cada una anota el municipio, cuántas viviendas se averiaron o destruyeron y, a veces, cuánto gastó el Estado en atenderla. De ahí sale lo que sabemos sobre **daños reales por sismo**.

Fuente	UNGRD, en datos.gov.co. Cuatro conjuntos: 2019, 2020, 2023-2024 y 2025. No hay archivos de 2021 ni de 2022
Fecha de descarga	13 de octubre de 2026
Tamaño	37.295 emergencias de todo el país. De ellas, 166 son sismos (el 0,4 %)
Qué trae	Fecha, departamento, municipio, tipo de evento, fallecidos, heridos, personas y familias afectadas, viviendas averiadas y destruidas, y el valor del apoyo del Fondo Nacional

Su limpieza es la más larga del proyecto y está en la sección 7.

1.5 Catálogo ANSS del USGS · Colombia

modelo 3

1.315 sismos de magnitud 4 o mayor en Colombia y alrededores, de 2019 a 2025 (descarga del 13/10/2026). Hace falta porque la UNGRD dice «hubo un sismo en tal municipio tal día», pero **no dice cuál sismo fue** ni qué magnitud tuvo. Con este catálogo lo identificamos.

¿Por qué no el del SGC? Porque solo tenemos el catálogo del SGC de Santander, y los sismos con daños ocurrieron en otros departamentos.

1.6 Población, viviendas y municipios del DANE

efectos de un sismo

Conjunto	Qué trae	Para qué
Proyecciones de población municipal 2018-2042	Habitantes por municipio y año. En 2026, Santander: 2.410.700 en 87 municipios	Contar personas expuestas a cada nivel de sacudida
Proyecciones de viviendas 2018-2042	Viviendas por municipio y año. En 2026, Santander: 948.340	Convertir «proporción afectada» en número de viviendas
DIVIPOLA	Código, nombre y coordenadas de cada municipio del país	Ubicar los municipios de las emergencias
Límites municipales (vía geoBoundaries)	El contorno de cada municipio	Dibujar el mapa y recortar el relieve

TÉCNICAMENTE

Son **proyecciones**, no conteos: el último censo es de 2018. La limpieza (`comun/src/preparar_poblacion.py`) toma solo Santander y el año 2026, pasa de una fila por área (cabecera, rural, total) a una fila por municipio, empareja los nombres con los del mapa sin tildes ni mayúsculas y comprueba que cabecera más rural dé el total en los 87 municipios.

OJO

La población y las viviendas **no son variables de ningún modelo de sismos**. Solo se usan después, para traducir una sacudida a personas y viviendas.

1.7 Relieve de JAXA

visualización

Modelo de elevación ALOS World 3D de 30 m, exportado con TouchTerrain en dos rectángulos: Los Santos (un punto cada 66 m) y todo Santander (cada 455 m). Sirve únicamente para dibujar las montañas en la aplicación. No interviene en ningún modelo.

1.8 Lo que se descargó, se evaluó y no se usó para entrenar

no se usó

Conjunto	Fuente	Por qué no
Fallas activas (18 que cruzan Santander)	SGC	Se probó la «distancia a la falla más cercana» como variable: importancia de 0,6 % a 1,5 % y ninguna mejora. Tiene sentido: el nido está a 150 km de profundidad, no en fallas superficiales
Contorno del nido sísmico	Gobernación de Santander	No es una variable, pero fue clave: mostró que el nido abarca 11 municipios (sección 3.3)
Remoción en masa e integración de amenazas	Gobernación de Santander	Son deslizamientos, incendios e inundaciones: no son sísmicos
Reporte de desastres de Santander	Gobernación de Santander	Registra 21 sismos desde 2018 con 55 viviendas averiadas y 0 destruidas: muy poco para aprender, pero confirma que el nido casi no causa daños

EN PALABRAS SIMPLES

No por tener más datos el modelo mejora. Probamos y medimos: lo que no ayudó se quedó fuera, y lo decimos.

2 La limpieza del catálogo

EN PALABRAS SIMPLES

El archivo del SGC llega «crudo»: el computador lo lee todo como texto, hasta los números. Para él, una magnitud de 3,2 es la palabra «3.2», y con palabras no se puede sumar. Limpiar es convertir cada cosa a lo que es (número, fecha) y revisar que no haya filas dañadas o repetidas.

Paso	Qué se hace	Por qué	Filas que quedan
0. Original	Se lee tal como llega, todo como texto	Para ver qué trae antes de tocarlo	184.723
1. Números	Magnitud, profundidad, coordenadas y medidas de calidad pasan de texto a número	Para poder calcular. Lo que no es un número queda como «faltante», **no como cero**	184.723
2. Fechas	La fecha pasa de texto a fecha, en hora universal (UTC)	Para ordenar y agrupar por trimestre	184.723
3. Datos esenciales	Se quitan las filas sin magnitud, profundidad, ubicación o fecha	Un sismo sin esos datos no se puede ubicar ni contar. **No hubo ninguna**	184.723
4. Repetidos	Se quitan los sismos con el mismo identificador	Para no contar dos veces el mismo. **No hubo ninguno**	184.723
5. Energía	Se calcula la energía de cada sismo: $\log_{10}(E) = 4{,}8 + 1{,}5\ M$	Un sismo de magnitud 5 libera 32 veces más energía que uno de 4: la magnitud sola no lo muestra	184.723

0
sismos perdidos en la limpieza

0
sismos repetidos

79.091
sin error de magnitud (42,8 %)

6 de 19
columnas usa el modelo

Qué se hizo con lo que faltaba

Después de limpiar siguen faltando datos en columnas secundarias: el error de la magnitud en 79.091 sismos, el error de la profundidad en 263 y el de la localización en 4.

EN PALABRAS SIMPLES

No inventamos nada. Lo fácil sería rellenar los huecos con ceros o con el promedio, pero eso es poner datos falsos. Como esas columnas el modelo no las usa, se dejan vacías y ya.

TÉCNICAMENTE

Sin imputación. Solo se descartaría una fila si le faltara un dato esencial (`magnitude` , `depth` , `latitude` , `longitude` , `utc_time`). Tampoco se eliminan valores extremos: los sismos grandes son reales y son los que interesan. Código: `comun/src/catalogo.py` , función `cargar_catalogo` .

Qué columnas se usan y cuáles no

Columna	¿Se usa?	Para qué, o por qué no
`magnitude`	**Sí**	**Filtro de 2,5 o más; magnitud media y máxima; sismos fuertes**
`depth`	**Sí**	**Profundidad media y qué tan dispersa es**
`latitude`, `longitude`	**Sí**	**Saber en qué celda cayó cada sismo**
`utc_time`	**Sí**	**Saber en qué trimestre ocurrió**
`energy_joules`	**Sí**	**Energía liberada en el último año (la calculamos nosotros)**
`id`	Solo en la limpieza	Detectar repetidos. Un identificador no predice nada
`agency`, `status`	No	No varían: todos son del SGC y 184.720 de 184.723 son soluciones manuales
`rms`, `gap`, `nst`, errores	No	Miden qué tan bien se localizó el sismo, no la sismicidad
`place`	No	El municipio que asigna el SGC. Justamente no confiamos en él: ubicamos por coordenadas
`mag_type`, `local_time`	No	Describen el método y repiten la fecha

¿Los datos están normalizados?

Depende de qué se entienda por «normalizado»:

- **Ordenados (una fila por caso, una columna por dato):** sí. Sin repetidos y, en el conjunto del modelo, sin faltantes.
- **Escalados (todos los números en la misma escala):** los archivos guardados **no**, a propósito: están en sus unidades reales para poder leerlos. El escalado ocurre dentro del modelo que lo necesita.

TÉCNICAMENTE

La Regresión Logística lleva un `StandardScaler` en su *pipeline*, ajustado solo con el periodo de entrenamiento, para no filtrar información de la prueba. El Random Forest no se escala porque no lo necesita: un árbol solo pregunta «¿esta variable es mayor que tal valor?», y la respuesta no cambia si se cambia la escala.

3 Las tres decisiones sobre los datos

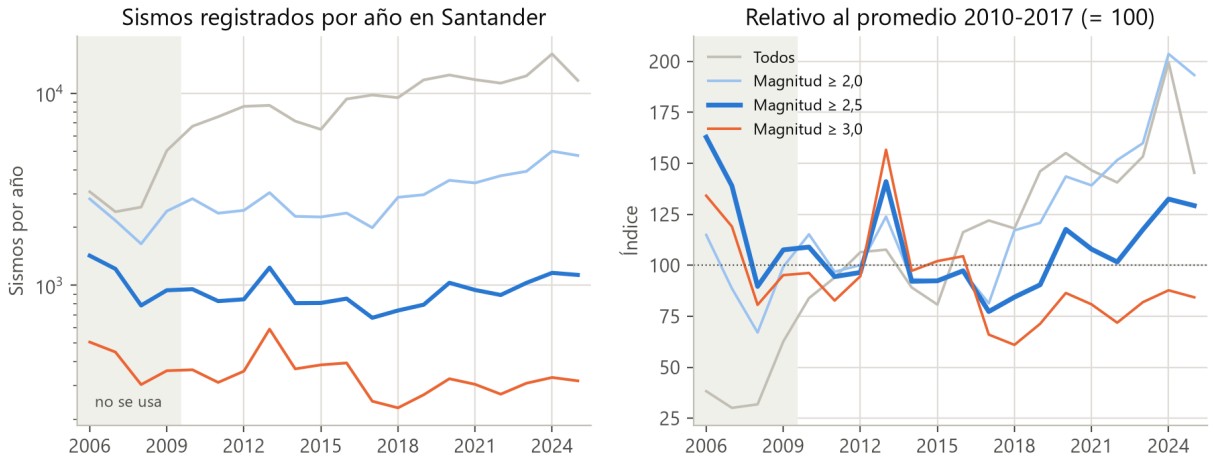
Estas tres decisiones pesaron más en el resultado que la elección del algoritmo.

3.1 ¿Por qué solo sismos de magnitud 2,5 o mayor?

EN PALABRAS SIMPLES

Imagina que cuentas cuántos pájaros hay en un parque. Un año cuentas a simple vista y al siguiente con binoculares. Vas a contar muchos más, pero no porque haya más pájaros: porque ahora ves los pequeños. Con los sismos pasa igual: el SGC ha puesto más sensores y ahora detecta temblores diminutos que antes no veía. Si los contamos todos, parece que Santander tiembla cada vez más, y es mentira. La solución es contar solo los pájaros grandes, los que siempre se vieron: los sismos de magnitud 2,5 o más.

Sismos por año (promedio)	2010 - 2017	2018 - 2025	Cambio	Lectura
Todos	8.026	12.085	+51 %	La red mejoró, no el nido
Magnitud 2,0 o mayor	2.451	3.766	+54 %	Todavía se nota la mejora de la red
Magnitud 2,5 o mayor	**876**	**965**	**+10 %**	**Casi estable: es el elegido**
Magnitud 3,0 o mayor	377	295	−22 %	No es más estable y quedan muy pocos



Sismos por año según el umbral de magnitud. A la derecha, relativo al promedio 2010-2017: solo la línea de 2,5 se mantiene cerca de 100.

TÉCNICAMENTE

Es un problema de **completitud del catálogo**: por debajo de cierta magnitud el catálogo no registra todos los sismos, y ese límite ha ido bajando con los años. El umbral de 2,5 es el más bajo que resulta razonablemente estable y que conserva suficientes sismos (unos 900 por año) para repartir entre las celdas.

OJO

No es perfecto: con 2,5 el conteo crece un 10 %. Lo decimos en las limitaciones. Un análisis formal de la magnitud de completitud año por año permitiría afinarlo.

3.2 ¿Por qué desde 2010?

EN PALABRAS SIMPLES

Antes de 2010 la red de sensores era otra, mucho más pequeña. Es como comparar fotos tomadas con dos cámaras distintas: no se pueden mezclar.

TÉCNICAMENTE

Entre 2006 y 2009 la magnitud más frecuente del catálogo era 2,2; desde 2010 es 1,6 o 1,7. Es decir, la red anterior apenas detectaba los sismos cercanos a nuestro umbral, y su conteo no es comparable: los sismos de magnitud 2,5 o más oscilan entre 1.426 (2006) y 785 (2008), y el total anual pasa de unos 2.500 en 2008 a 6.731 en 2010. Desde 2010, el conteo de magnitud 2,5 o más se mantiene entre 677 y 1.235 por año. Además, las variables necesitan un año de historia, así que la primera predicción es para 2011.

3.3 ¿Por qué el catálogo de todo Santander, si la zona es Los Santos?

EN PALABRAS SIMPLES

Al principio bajamos solo los sismos del municipio de Los Santos. Pero el nido no sabe de límites municipales: se extiende por debajo de los municipios vecinos. El SGC le pone a cada sismo el nombre del municipio donde cae su epicentro, así que un temblor a 200 metros del límite quedaba como «Zapatoca» y no lo teníamos, aunque caía dentro de nuestra cuadrícula. **Nos faltaba uno de cada ocho sismos de nuestra propia zona.**

Municipio que el SGC le asigna	Sismos M≥2,5 dentro de nuestras 30 celdas
Los Santos	11.964
Zapatoca	1.407
Cepitá	135
Villanueva	130
Otros (Jordán, Betulia, Girón, Piedecuesta…)	105
Faltaban en total	**1.777 (12,9 %)**

Cómo lo descubrimos: revisando una capa oficial de la Gobernación de Santander que dibuja el nido sobre 11 municipios.

Qué arregló:

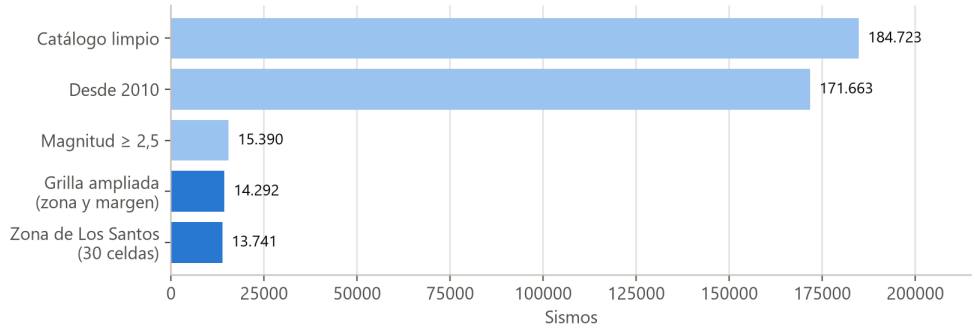
- 14 de las 30 celdas parecían vacías y se reportaban «Bajo» sin pasar por el modelo. Ahora las 30 tienen datos y las 30 pasan por el modelo.

- 25 de las 304 respuestas correctas del periodo de prueba estaban mal.
- Cada celda del borde ahora «ve» a sus vecinas: las variables se calculan en una cuadrícula ampliada cinco celdas (unos 28 km) a cada lado.

OJO

Seguimos prediciendo solo Los Santos, que es la zona elegida para el reto. El catálogo de Santander se usa para que a esa zona no le falten sismos. Ahora cada sismo se ubica por sus coordenadas, no por el municipio que diga el catálogo.

El embudo completo



De 184.723 sismos del catálogo a los 13.741 que caen en las 30 celdas de Los Santos.

Usamos cerca del 8 % del catálogo. Es a propósito: lo que se descarta son los sismos que no se registraron de forma comparable a lo largo del tiempo.

4 Entrenamiento 1 · Sismos de Los Santos

Es el modelo principal: el que responde al reto de la categoría Básica. Carpeta: `entrenamiento/1_sismos_los_santos`.

4.1 Qué es «un caso»

EN PALABRAS SIMPLES

El reto pide clasificar **zonas**, no sismos. Entonces partimos Los Santos en una cuadrícula de 30 cuadros de 5,5 km de lado y el tiempo en trimestres. Cada «caso» es una foto de un cuadro en un trimestre: «en el cuadro 8, a marzo de 2023, había pasado esto». Y la pregunta es: ¿qué pasará en ese cuadro el trimestre siguiente?

TÉCNICAMENTE

Celdas de 0,05° entre 6,70° y 6,95° N y entre 73,25° y 72,95° O (5 filas por 6 columnas). 67 trimestres completos, de 2010-T1 a 2026-T3. Como las variables necesitan un año de historia y la etiqueta necesita el trimestre siguiente, quedan 63 trimestres por celda: **1.890 casos**, sin faltantes ni repetidos.

4.2 La etiqueta: qué es bajo, medio y alto

Nivel	Sismos de magnitud 2,5 o más en el trimestre siguiente	Entrenamiento	Prueba
Bajo	Ninguno	878	350
Medio	De 1 a 3 (hasta uno por mes en promedio)	186	86
Alto	Más de 3	256	134

OJO: ¿ESTO NO ES UNA REGLA FIJA?

No. Una regla fija sería «si la celda tuvo más de 3 sismos, es alta». Aquí la etiqueta es lo que pasó **después**, y el modelo tiene que adivinarlo con lo que pasó antes. Los umbrales (0 y 3) solo definen los tres niveles; lo que se aprende es a anticiparlos.

4.3 Las 15 variables

Todas se calculan con lo ocurrido **hasta** el trimestre que termina. Nunca usan el futuro.

Variable	En palabras simples	Peso en el modelo
`sismos_ultimo_anio`	Cuánto tembló aquí el último año	16,2 %
`sismos_trimestre`	Cuánto tembló aquí estos tres meses	15,5 %
`sismos_vecinos_ultimo_anio`	Cuánto tembló en los 8 cuadros de alrededor	12,6 %
`dist_nido_km`	Qué tan lejos está del centro del nido	12,4 %
`log_energia_ultimo_anio`	Cuánta energía se liberó aquí el último año	9,3 %
`prof_std_ultimo_anio`	Si los sismos fueron todos a la misma profundidad o dispersos	6,1 %
`mag_max_ultimo_anio`	El más fuerte del último año	5,6 %
`sismos_promedio_historico`	Lo normal en este cuadro desde 2010	5,4 %
`prop_moderados_ultimo_anio`	Qué parte de los sismos fue de magnitud 3,5 o más	4,7 %
`mag_media_ultimo_anio`	Magnitud promedio	3,0 %
`trimestres_desde_sismo_fuerte`	Hace cuánto no hay uno de magnitud 4 o más	2,9 %
`prof_media_ultimo_anio`	Profundidad promedio	2,1 %
`lon_center`, `lat_center`	Dónde está el cuadro	1,9 % y 0,8 %
`tendencia_sismos`	Si va subiendo o bajando frente al último año	1,3 %

Lo que más pesa tiene lógica: donde ha temblado, sigue temblando; la actividad se contagia a los cuadros vecinos; y todo se concentra cerca del núcleo del nido.

4.4 Cómo se separan entrenamiento y prueba

EN PALABRAS SIMPLES

Es como estudiar para un examen: si te dejan ver las preguntas antes, sacar 5 no prueba nada. Por eso el modelo estudia con los años 2011 a 2021 y se le examina con 2022 a 2026, **casi cinco años que nunca vio**. No se mezclan al azar, porque entonces estaría viendo el futuro para adivinar el pasado.

TÉCNICAMENTE

Partición temporal. Entrenamiento: trimestres objetivo de 2011-T1 a 2021-T4 (1.320 casos). Prueba: 2022-T1 a 2026-T3 (570 casos). Una partición aleatoria habría dado métricas falsamente altas por fuga temporal.

4.5 Qué modelos se probaron

RANDOM FOREST (EL ELEGIDO)

Un árbol de decisión es un juego de preguntas: «¿tembló más de 5 veces el último año? ¿está a menos de 10 km del nido?», hasta llegar a una respuesta. Un *bosque* son 300 árboles, cada uno entrenado con una parte distinta de los datos, que votan. Entre todos se equivocan menos que uno solo.

REGRESIÓN LOGÍSTICA (LA REFERENCIA)

Un modelo más sencillo: le pone un peso a cada variable y suma. Sirve para saber si la complejidad del bosque de verdad aporta algo.

TÉCNICAMENTE

`RandomForestClassifier` con 300 árboles, mínimo 5 casos por hoja y semilla 42 (Breiman, 2001). `LogisticRegression` con variables estandarizadas y clases balanceadas. Ambos de scikit-learn 1.9.1. Entrena en segundos, sin tarjeta gráfica: son 1.320 casos, no millones.

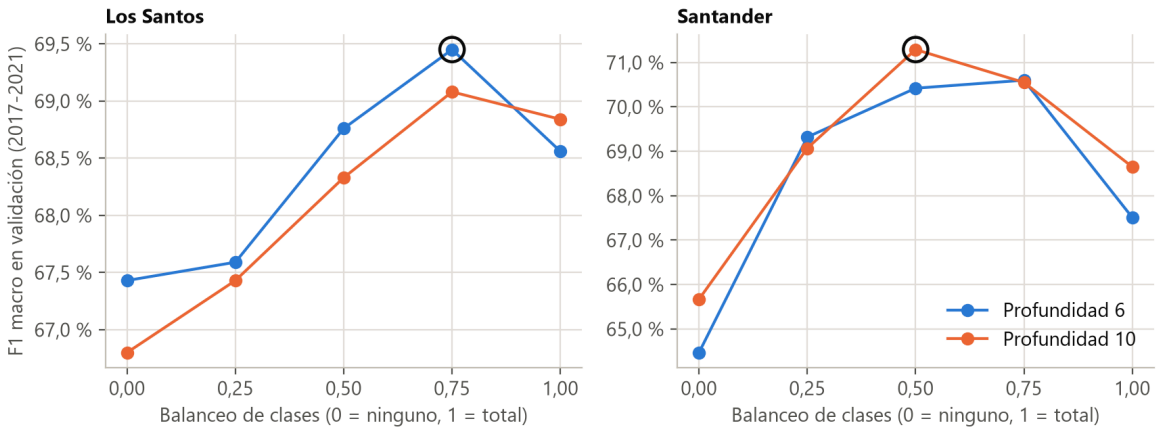
4.6 Los dos ajustes, y cómo se eligieron sin hacer trampa

El bosque tiene dos perillas que no fijamos a mano:

- **Balanceo.** Hay muchos más casos «Bajo» que «Alto». Si no se compensa, el modelo aprende a decir «Bajo» casi siempre. Si se compensa del todo, da demasiadas falsas alarmas. El balanceo es un número de 0 (no compensar) a 1 (que las tres clases pesen igual).
- **Profundidad.** Cuántas preguntas seguidas puede hacer cada árbol. Con pocas no aprende; con demasiadas se aprende los datos de memoria.

EN PALABRAS SIMPLES

Para elegir esas perillas no usamos el examen final (eso sería trampa). Hicimos **simulacros dentro del periodo de estudio**: entrenar hasta 2016 y adivinar 2017; hasta 2017 y adivinar 2018; así hasta 2021. La combinación que mejor salió en los simulacros es la que se usa.



Resultado de los simulacros (validación interna 2017-2021) para cada combinación. El círculo es la elegida.

TÉCNICAMENTE

Validación hacia adelante con origen expansivo sobre 2017-2021, rejilla de balanceo {0; 0,25; 0,5; 0,75; 1} por profundidad {6; 10}, criterio F1 macro promedio. Peso de cada clase: (casos / (3 × casos de la clase))^{balanceo}. Elegido para Los Santos: **balanceo 0,75 y profundidad 6** (F1 macro 69,5 % y exactitud 80,8 % en validación). Función `elegir_ajustes` .

4.7 Contra qué se compara

Un 80 % no dice nada si no se sabe cuánto se saca sin modelo. Por eso se compara con tres reglas que no aprenden:

- **Clase más frecuente:** decir siempre «Bajo».
- **Persistencia:** «el próximo trimestre será igual a este». Es la rival difícil, porque la sismicidad es muy persistente.
- **Promedio del último año.**

4.8 Cómo se mide

Métrica	En palabras simples
Exactitud	De cada 100 casos, cuántos acertó
F1 macro	Una nota que promedia qué tan bien le va en cada uno de los tres niveles, **dándoles el mismo peso**. Castiga al modelo que solo acierta el nivel más común
Recall del nivel Alto	De los casos que de verdad fueron «Alto», cuántos detectó. Es el que importa para prevención
Matriz de confusión	Una tabla que muestra con qué se confunde: si dijo «Medio» cuando era «Alto», etc.

4.9 Resultados

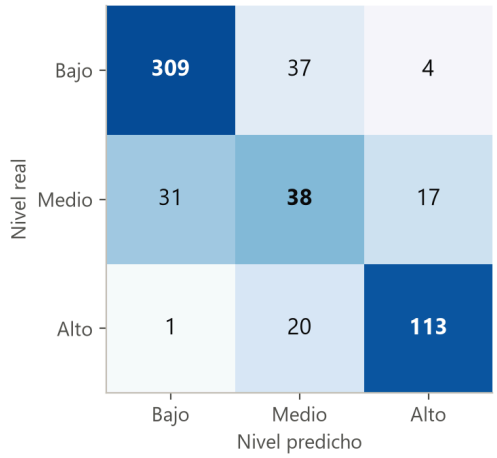
80,7 %
exactitud

71,9 %
F1 macro

84,3 %
recall del nivel Alto

570
casos de prueba

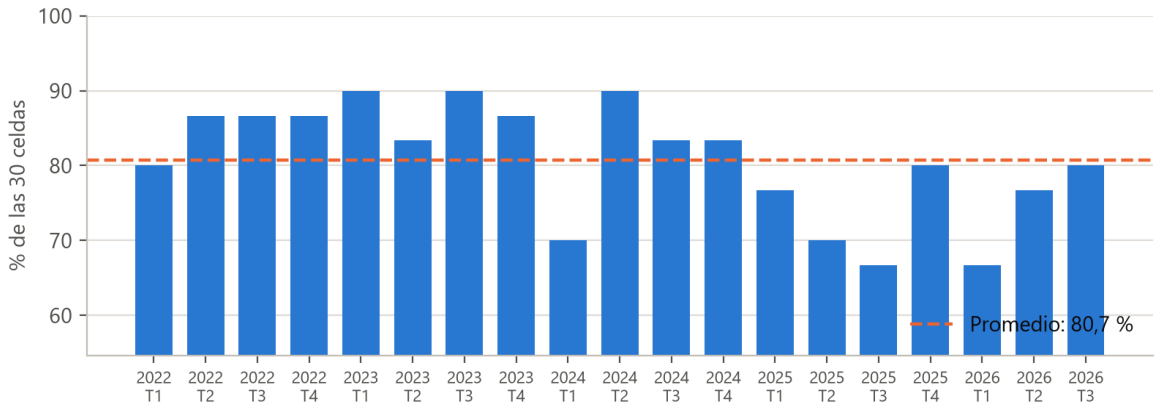
Modelo	Exactitud	F1 macro	Recall Alto
Regla: clase más frecuente	61,4 %	25,4 %	0,0 %
Regla: igual al trimestre anterior (persistencia)	80,2 %	70,9 %	86,6 %
Regla: promedio del último año	70,9 %	66,5 %	93,3 %
Regresión Logística	76,3 %	70,5 %	81,3 %
Random Forest (elegido)	**80,7 %**	**71,9 %**	**84,3 %**
Techo de referencia (oráculo)	*82,8 %*	*72,3 %*	*91,8 %*



Matriz de confusión. Filas: lo real. Columnas: lo predicho.

Cómo leer la matriz

- La diagonal son los aciertos: 309, 38 y 113.
- **Falla por poco:** solo 4 veces dijo «Alto» siendo «Bajo», y solo 1 vez dijo «Bajo» siendo «Alto».
- **El nivel Medio es el difícil:** acierta 38 de 86. Con uno a tres sismos por trimestre manda el azar.



Celdas acertadas en cada uno de los 19 trimestres de prueba. No empeora con los años.

4.10 ¿Por qué no llega al 100 %? El techo

EN PALABRAS SIMPLES

Los sismos tienen azar. Una zona que en promedio tiene dos temblores por trimestre a veces tiene cero y a veces cinco, y eso nadie lo puede adivinar. Para saber cuánto se puede acertar como máximo, construimos un «oráculo»: un tramposo que conoce el promedio real de cada zona, incluso mirando el futuro. Ese tramposo acierta 82,8 %. Nuestro modelo, sin trampa, acierta 80,7 %: **el 97 % de lo posible**.

TÉCNICAMENTE

El oráculo toma la tasa media de la celda en los 9 trimestres alrededor del que se predice (incluidos los posteriores) y elige el nivel más probable según una distribución de Poisson. No es un límite matemático, es una referencia. Se confirmó probando Gradient Boosting, ExtraTrees y otras configuraciones, siempre elegidas con validación interna: ninguna mejoró de forma consistente.

OJO: LO QUE HAY QUE DECIR CON HONESTIDAD

La ventaja sobre la persistencia es pequeña: 80,7 % frente a 80,2 % de exactitud, y la persistencia detecta algo mejor el nivel Alto (86,6 % frente a 84,3 %). No es que el modelo sea malo: es que el fenómeno es tan persistente que queda poco margen. Estamos cerca del techo.

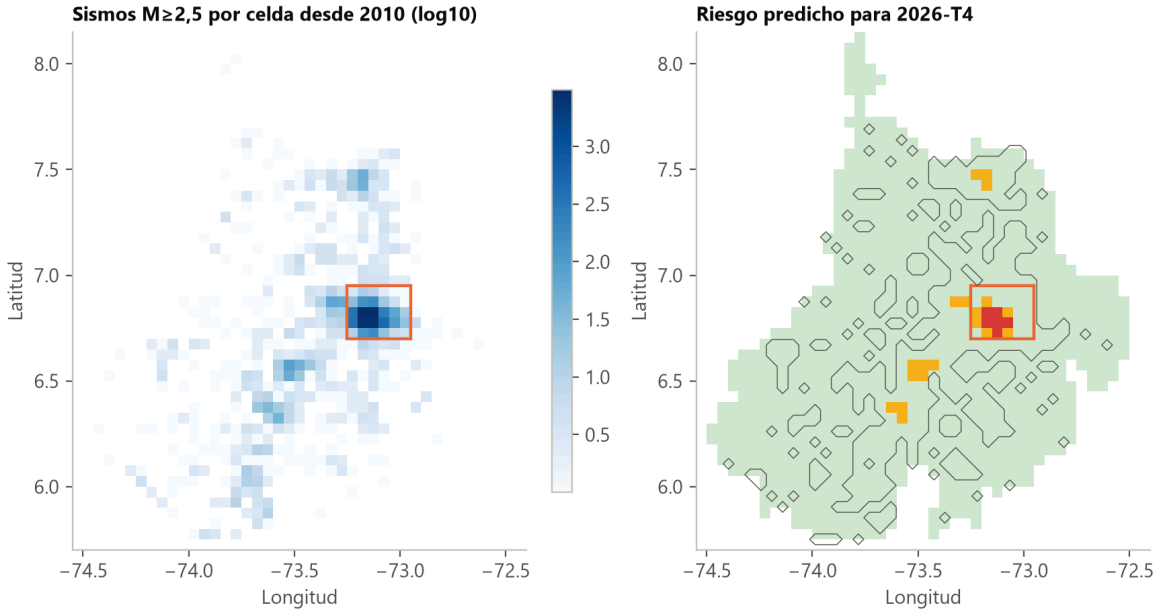
Con el desempeño ya medido, el modelo final se entrena con **todos** los casos y da la predicción vigente, para 2026-T4: 19 celdas en Bajo, 7 en Medio y 4 en Alto.

5 Entrenamiento 2 · Sismos de todo Santander

Carpeta: `entrenamiento/2_sismos_santander` . Es **el mismo clasificador**: mismas 15 variables, misma etiqueta, misma partición temporal. Solo cambia el territorio.

TÉCNICAMENTE

Cuadrícula de 49 por 43 celdas de 0,05° sobre el rectángulo de Santander. De las 997 cuyo centro cae dentro del departamento, **358** tuvieron sismos en el periodo de entrenamiento y son las que se modelan; el resto se reporta «Bajo». Resultan **22.554 casos**: 15.752 de entrenamiento y 6.802 de prueba. El script reutiliza el código del modelo 1 y solo cambia la cuadrícula y los archivos de salida.



Izquierda: sismos por celda desde 2010. Derecha: riesgo predicho para 2026-T4. El recuadro naranja es la zona del modelo 1.

La trampa de la exactitud

EN PALABRAS SIMPLES

En Santander casi todo está quieto: el 92 % de los casos son «Bajo». Entonces un modelo tonto que diga siempre «Bajo» acierta el 91,7 %, y no sirve para nada, porque no detecta ni un solo caso importante. Por eso aquí **la exactitud engaña** y miramos el F1, que le da el mismo peso a los tres niveles.

Modelo	Exactitud	F1 macro	Recall Alto
Regla: clase más frecuente (siempre «Bajo»)	91,7 %	31,9 %	0,0 %
Regla: igual al trimestre anterior (persistencia)	90,9 %	70,0 %	86,6 %
Regla: promedio del último año	83,0 %	68,2 %	93,3 %
Regresión Logística	84,1 %	68,4 %	97,8 %
Random Forest (elegido)	**93,4 %**	**74,3 %**	**89,6 %**
Techo de referencia (oráculo)	*94,2 %*	*73,6 %*	*91,8 %*

Aquí el Random Forest le gana con claridad a la persistencia: 93,4 % frente a 90,9 % de exactitud y 74,3 % frente a 70,0 % de F1. De 134 casos «Alto» detecta 120, y solo 2 se le escapan como «Bajo».

El balanceo fue decisivo

La validación interna eligió **balanceo 0,5 y profundidad 10**. Con las tres clases pesando igual (balanceo 1), el modelo daba demasiadas falsas alarmas y su exactitud bajaba a 87,5 %, por debajo de la persistencia. Ajustarlo lo subió a 93,4 %.

¿Por qué dos modelos y no uno?

EN PALABRAS SIMPLES

Probamos usar un solo modelo para todo. En Los Santos la exactitud se cayó de 79 % a 63 %. La razón: fuera del nido casi todos los cuadros están vacíos y se comportan distinto, y el modelo aprende de ellos una lección que adentro no sirve. Es como entrenar a un médico de urgencias solo con pacientes sanos. **Cada modelo, en su zona.**

OJO

Más datos no siempre es mejor. Usar todos los **sismos** de Santander sí ayudó (sección 3.3); usar todas las **celdas** de Santander para entrenar el modelo de Los Santos, no.

6 El simulador de sacudida

Carpeta: `entrenamiento/comun`. Los clasificadores dicen *dónde* habrá más actividad; el simulador dice *qué tan fuerte se sentiría* un sismo dado en cada punto de Santander.

Cómo funciona

EN PALABRAS SIMPLES

Tiene dos partes. Primero, una **fórmula de la física** que los sismólogos ya publicaron: dada la magnitud, la profundidad y la distancia, dice cuánto se mueve el suelo. Segundo, un **ajuste con datos reales**: comparamos la fórmula con lo que la gente reportó en 86 sismos del nido y corregimos lo que la fórmula se equivocaba.

TÉCNICAMENTE

- **Física:** aceleración máxima del suelo con Zhao et al. (2006), en su versión intraplaca para profundidades de 50 km o más; conversión a intensidad de Mercalli con Worden et al. (2012).
- **Calibración:** una regresión lineal aprende el *residuo* (intensidad reportada menos intensidad física) a partir de la magnitud y el logaritmo de la distancia. Cada observación pesa la raíz del número de respuestas: un lugar con 50 respuestas es más fiable que uno con una.
- **Niveles:** Bajo hasta intensidad IV, Medio de V a VI, Alto desde VII.

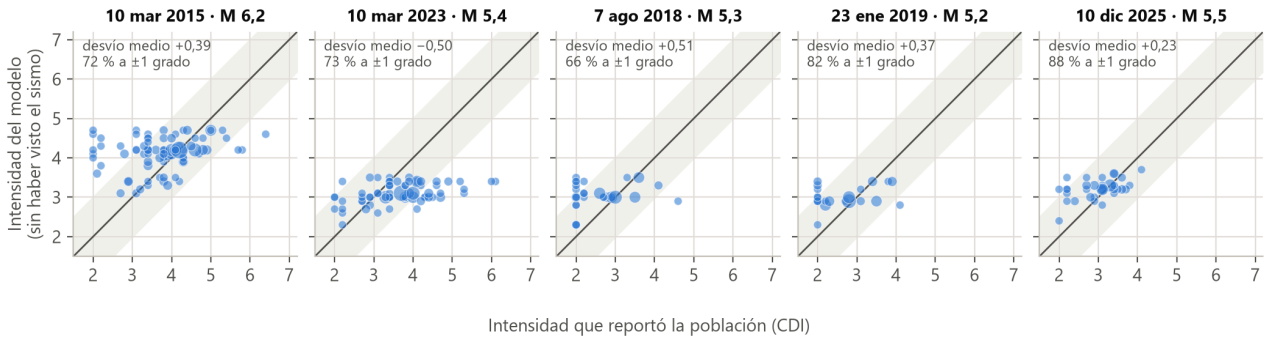
Cómo se validó

EN PALABRAS SIMPLES

De los 86 sismos, se esconde uno completo, se ajusta el simulador con los otros 85 y se le pide adivinar el escondido. Y así 86 veces. De ese modo el simulador **nunca ve el sismo que tiene que predecir**.

Alternativa	Error (grados Mercalli)	Acierta a ±1 grado
Fórmula física sola	1,04	68,1 %
Física + corrección constante	0,96	73,2 %
Física + regresión lineal (elegida)	**0,80**	**82,3 %**
Física + Random Forest	0,85	77,4 %
Física + Random Forest con ubicación	0,84	78,3 %
Regresión lineal sin física (referencia)	0,81	81,9 %
Random Forest sin física (referencia)	0,87	75,9 %

La calibración le quitó un 23 % de error a la fórmula. Y **lo simple ganó**: con solo 598 observaciones, una recta generaliza mejor que un bosque. Los modelos «sin física» sacan un error parecido, pero no sirven para simular: no saben qué pasa si uno cambia la profundidad.



Los cinco sismos con más reportes: intensidad del simulador frente a la que reportó la gente. La franja gris es ±1 grado.

OJO

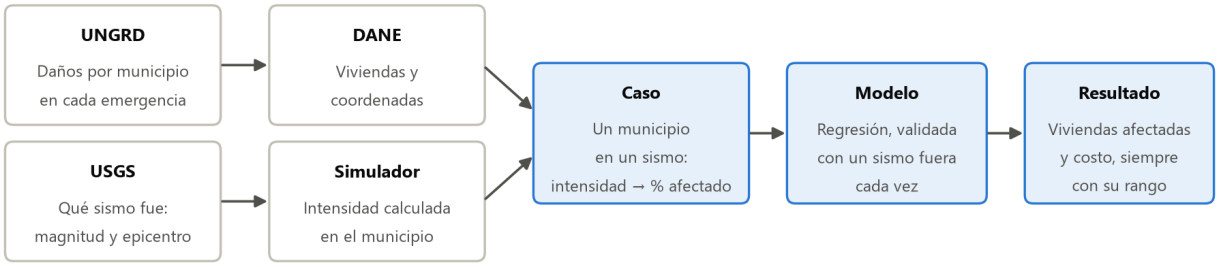
- Está validado para magnitudes de 4,5 a 6,2 y profundidades de 135 a 177 km. Fuera de eso es extrapolación, y la aplicación lo avisa.
- Acierta el nivel general de cada sismo, pero no las diferencias entre lugares cercanos: a 150 km de profundidad la intensidad calculada casi no cambia con la distancia, mientras la gente reporta de II a VI según su suelo y su edificio.
- Supone el mismo tipo de suelo en todas partes.

7 Entrenamiento 3 · Viviendas afectadas y costo

Carpeta: `entrenamiento/3_viviendas_y_costos`. Responde lo que el simulador deja abierto: si un sismo sacude un municipio con cierta intensidad, ¿cuántas viviendas se afectan y cuánto cuesta atenderlas?

EN PALABRAS SIMPLES

En Santander no hay de dónde aprender esto: los sismos del nido son tan profundos que casi no dañan nada (21 sismos reportados desde 2018, 55 viviendas averiadas, ninguna destruida). Así que el modelo aprende de **sismos de todo el país** que sí causaron daños.

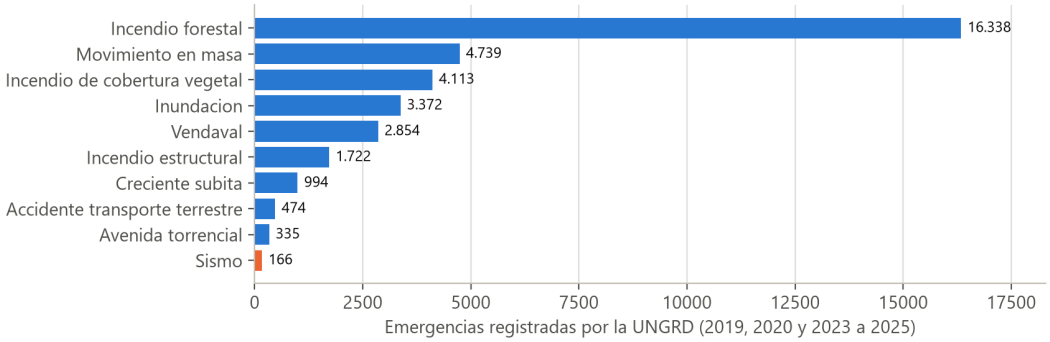


De cuatro fuentes a un caso: «este municipio, en este sismo, con esta intensidad, tuvo este porcentaje de viviendas afectadas».

7.1 La limpieza, paso a paso

Es la más laboriosa del proyecto, porque hay que juntar cuatro fuentes que no fueron hechas para juntarse. Script: `preparar_danos.py`.

Paso	Qué se hace	Resultado
1. Unir	Los cuatro archivos de la UNGRD tienen entre 61 y 74 columnas, con nombres distintos para lo mismo («viviendas averiadas», «viv_aver»…). Se llevan todos a las mismas columnas	37.295 emergencias (1 sin fecha, descartada)
2. Números	Los conteos pasan de texto a número; «No Registra» cuenta como cero. A los valores en pesos se les quitan símbolos y separadores («$ 1,234,567.00»)	Todo calculable
3. Solo sismos	Se toman las emergencias cuyo tipo de evento es sismo	166 emergencias
4. Municipio	Se reconoce cada municipio comparando nombres sin tildes ni mayúsculas con la tabla DIVIPOLA, y se le añaden sus coordenadas y las viviendas que tenía ese año	3 sin municipio válido (dos son «Océano Pacífico» y «Perú»)
5. ¿Cuál sismo fue?	Entre los sismos del catálogo del USGS de ese día y los dos anteriores, se elige el que más habría sacudido al municipio, y se calcula su intensidad con la fórmula física	3 emergencias sin ningún sismo
6. Actualizaciones	Si un municipio reportó varias veces el mismo sismo, se deja el reporte mayor	**120 casos de 27 sismos**



Los sismos (en naranja) son una parte mínima de las emergencias del país.

7.2 Lo que muestran los datos limpios

Intensidad calculada	Casos	Con viviendas afectadas	Viviendas afectadas	Proporción mediana
Hasta III	18	7	8	0 %
III a IV	42	17	202	0 %
IV a V	41	36	1.231	0,03 %
V a VI	16	13	1.685	0,6 %
VI a VII	3	3	692	21 %

Hay señal: a más intensidad, más daño. En total, 3.620 viviendas averiadas y 198 destruidas en 76 de los 120 casos.

7.3 El modelo

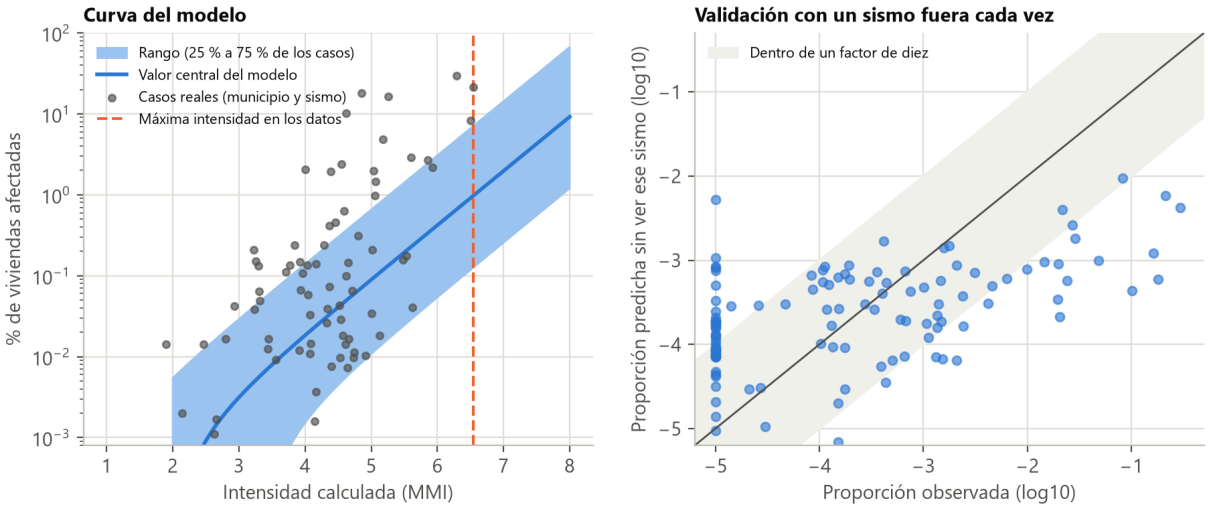
EN PALABRAS SIMPLES

Lo que se predice es «qué porcentaje de las viviendas del municipio se afecta». Ese porcentaje va desde casi cero hasta más del 20 %, un rango enorme, así que el modelo trabaja con su **logaritmo** (que convierte «10 veces más» en «un escalón más»). El modelo que ganó es el más sencillo posible: una **línea recta** entre la intensidad y ese logaritmo.

Candidato	Error típico	Dentro de un factor 10	Orden correcto
Referencia: decir siempre la mediana	× 20	38 %	−0,21
Recta sobre el logaritmo, según la intensidad (elegido)	**× 12**	**63 %**	**0,53**
Curva logística según la intensidad	× 36	43 %	0,53
Random Forest con intensidad, magnitud, profundidad y distancia	× 17	61 %	0,41

TÉCNICAMENTE

Objetivo: $\log_{10}(\text{proporción} + 10^{-5})$. Validación dejando fuera un sismo completo cada vez (27 pliegues), igual que en el simulador. «Error típico × 12» es la raíz del error cuadrático medio en escala logarítmica (1,07) pasada a factor. «Orden correcto» es la correlación de rangos de Spearman entre lo predicho y lo observado. Script `entrenar_modelo_viviendas.py` ; el uso del modelo está en `modelo_de_danos.py` , el mismo archivo que usa el backend.



Izquierda: la recta aprendida, su rango y los 120 casos reales. Derecha: lo predicho frente a lo observado, con un sismo fuera cada vez.

OJO: ESTE MODELO ES DÉBIL, Y LO DECIMOS

- **Se equivoca por un factor de diez.** Puede dar diez veces más o diez veces menos viviendas que las reales. Mejora un 17 % a la referencia y ordena bien los casos, pero nada más.
- **Por qué:** son solo 120 casos; la intensidad es calculada, no medida; los municipios que no reportaron no aparecen; y con la misma intensidad el daño depende de cómo estén construidas las casas, y ese dato no lo tenemos.
- **No hay datos por encima de intensidad 6,5.** Más arriba es extrapolación (solo 3 casos sobre intensidad VI).
- **Por eso siempre entrega un rango,** nunca una sola cifra: entre el 25 % y el 75 % de los casos, el valor real quedó entre 0,13 y 7,3 veces el central.

7.4 El costo

EN PALABRAS SIMPLES

Para pasar viviendas a pesos miramos cuánto gastó el Estado, por vivienda afectada, en las emergencias donde anotó el valor. Como casi ningún sismo tiene valor anotado, usamos emergencias de todo tipo. Y como el gasto varía muchísimo, damos tres valores en vez de uno.

Valor	Qué significa	Pesos por vivienda afectada
Bajo	El 25 % de las emergencias gastó menos que esto	1,4 millones
Medio	**La mitad gastó menos, la mitad más (mediana)**	**7,9 millones**
Alto	El 25 % gastó más que esto	54,1 millones

TÉCNICAMENTE

Solo 768 de las 37.295 emergencias (el 2 %) registran apoyo mayor que cero. De ellas, 296 tienen además viviendas afectadas, y solo 2 son sismos. Los tres valores son los cuartiles de apoyo dividido entre viviendas afectadas en esas 296.

OJO

No es una indemnización ni el costo de reconstruir. Es lo que el Fondo Nacional gastó en atención: asistencia humanitaria, materiales y subsidios de arriendo. En Colombia el Estado no indemniza los daños por desastre; da ayudas.

Ejemplo en la aplicación: un sismo de magnitud 6,4 a 150 km de profundidad da unas 412 viviendas afectadas (entre 46 y 3.052, de 948.340), 12 destruidas y un costo de atención de unos 3.272 millones de pesos (entre 62,5 y 165.050 millones).

8 Preguntas que puede hacer el jurado

¿Por qué descartaron el 92 % de los sismos?

Porque los sismos pequeños no se registraron igual todos los años: la red mejoró. Si los contáramos, el modelo aprendería la mejora de la red, no la sismicidad. Con magnitud 2,5 o más desde 2010 el conteo es comparable en el tiempo.

Si la zona es Los Santos, ¿por qué usan datos de todo Santander?

Porque el nido se extiende bajo los municipios vecinos y el SGC asigna cada sismo a un municipio. Filtrando por «Los Santos» nos faltaba el 12,9 % de los sismos de nuestra propia cuadrícula. Predecimos solo Los Santos; el catálogo completo es para no perder sismos.

¿La etiqueta no es una regla fija?

No. La etiqueta es lo que pasó el trimestre siguiente. El modelo debe anticiparlo con lo que pasó antes, y se compara contra reglas fijas, a las que supera.

¿Cómo saben que el modelo no hizo trampa?

Se probó con casi cinco años que nunca vio (2022 a 2026), las variables solo usan el pasado, y hasta los ajustes del modelo se eligieron con simulacros dentro del periodo de entrenamiento, sin tocar la prueba.

80,7 % contra 80,2 % de la persistencia: ¿eso es ganar?

Es ganar por poco, y lo decimos. La sismicidad es tan persistente que la regla simple ya es muy buena. Calculamos que el máximo alcanzable es 82,8 %, así que estamos al 97 % del techo. En Santander la ventaja es clara: 93,4 % contra 90,9 %, y 74,3 % contra 70,0 % de F1.

¿Por qué Random Forest y no una red neuronal?

Son 1.320 casos con 15 variables en tabla: para eso los árboles funcionan mejor y son más fáciles de explicar. Probamos Gradient Boosting y ExtraTrees y no mejoraron. Con tan pocos datos, un modelo más complejo se aprende los datos de memoria.

¿Normalizaron los datos?

Donde hace falta. La Regresión Logística escala sus variables con datos de entrenamiento únicamente. El Random Forest no lo necesita, porque solo compara cada variable contra un umbral.

¿Pueden predecir cuándo va a temblar?

No, y nadie puede. El modelo dice qué zonas estarán más activas el próximo trimestre, que es otra cosa.

¿Qué tan confiable es la cifra de viviendas y de costo?

Poco: es un orden de magnitud. El modelo se equivoca por un factor de diez, por eso siempre muestra un rango. Y el costo es gasto de atención del Estado, no indemnización. La aplicación lo dice en pantalla.

¿Qué harían con más tiempo?

Un análisis formal de la completitud del catálogo año por año; datos de cómo están construidas las viviendas (del censo) para el modelo de daños; población por vereda en lugar de por municipio; y desplegar el sistema para contrastar la predicción de 2026-T4 cuando termine el trimestre.

Glosario

Aprendizaje supervisado	Enseñarle a un modelo con ejemplos que ya traen la respuesta correcta.
Balanceo de clases	Compensar que haya muchos más ejemplos de un nivel que de otro.
Caso	En los modelos 1 y 2: una celda en un trimestre. En el modelo 3: un municipio en un sismo.
Celda	Cada cuadro de 5,5 km en que se divide el mapa.
Completitud	La magnitud a partir de la cual el catálogo registra todos los sismos.
Etiqueta	La respuesta correcta de cada caso: Bajo, Medio o Alto.
Fuga de información	Que el modelo vea, sin querer, datos del futuro o de la prueba.
Intensidad (Mercalli)	Qué tan fuerte se siente un sismo en un lugar, de I a X. No es la magnitud: la magnitud es una sola por sismo; la intensidad cambia de un lugar a otro.
Oráculo o techo	Un modelo imaginario que conoce la tasa real de cada celda; marca cuánto se puede acertar.
Persistencia	La regla «el próximo trimestre será igual a este».
Residuo	Lo que le falta o le sobra a una predicción frente a lo observado.
Validación interna	Simulacros hechos dentro del periodo de entrenamiento para elegir ajustes sin tocar la prueba.