Modelo 2 · Sismos de todo Santander · Registro del entrenamiento

UTSmart IA Challenge 2027 – Categoría Básica

Es el mismo clasificador del modelo 1 (mismas 15 variables, misma etiqueta y misma partición temporal), aplicado a una grilla que cubre todo el departamento. Va en un modelo aparte porque un solo modelo para las dos zonas predice peor en Los Santos: fuera del nido casi todas las celdas están vacías y se comportan distinto.

La limpieza del catálogo es la misma del modelo 1 y está registrada paso a paso en su cuaderno (`1_sismos_los_santos/notebooks`). Aquí se registra lo propio de este modelo: la grilla, el conjunto de datos, el entrenamiento y los resultados.

> **Estado: entrenado y evaluado.**

In [1]:
```
import json
import sys
import warnings
from pathlib import Path

import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from IPython.display import display

warnings.filterwarnings("ignore")
MODELO = Path.cwd().parent
sys.path.insert(0, str(MODELO / "src"))
sys.path.insert(0, str(MODELO.parent / "comun" / "src"))
pd.set_option("display.max_columns", 40, "display.width", 200, "display.float_forma
AZUL, NARANJA = "#2a78d6", "#eb6834"
COLOR_NIVEL = {"Bajo": "#1baf1b", "Medio": "#f5b21a", "Alto": "#d83a3a"}
plt.rcParams.update({"figure.dpi": 110, "axes.spines.top": False, "axes.spines.righ
                     "axes.grid": True, "grid.color": "#e1e0d9", "axes.axisbelow":

import catalogo
import entrenar_modelo_sismico_santander as santander
clasificador = santander.clasificador
```

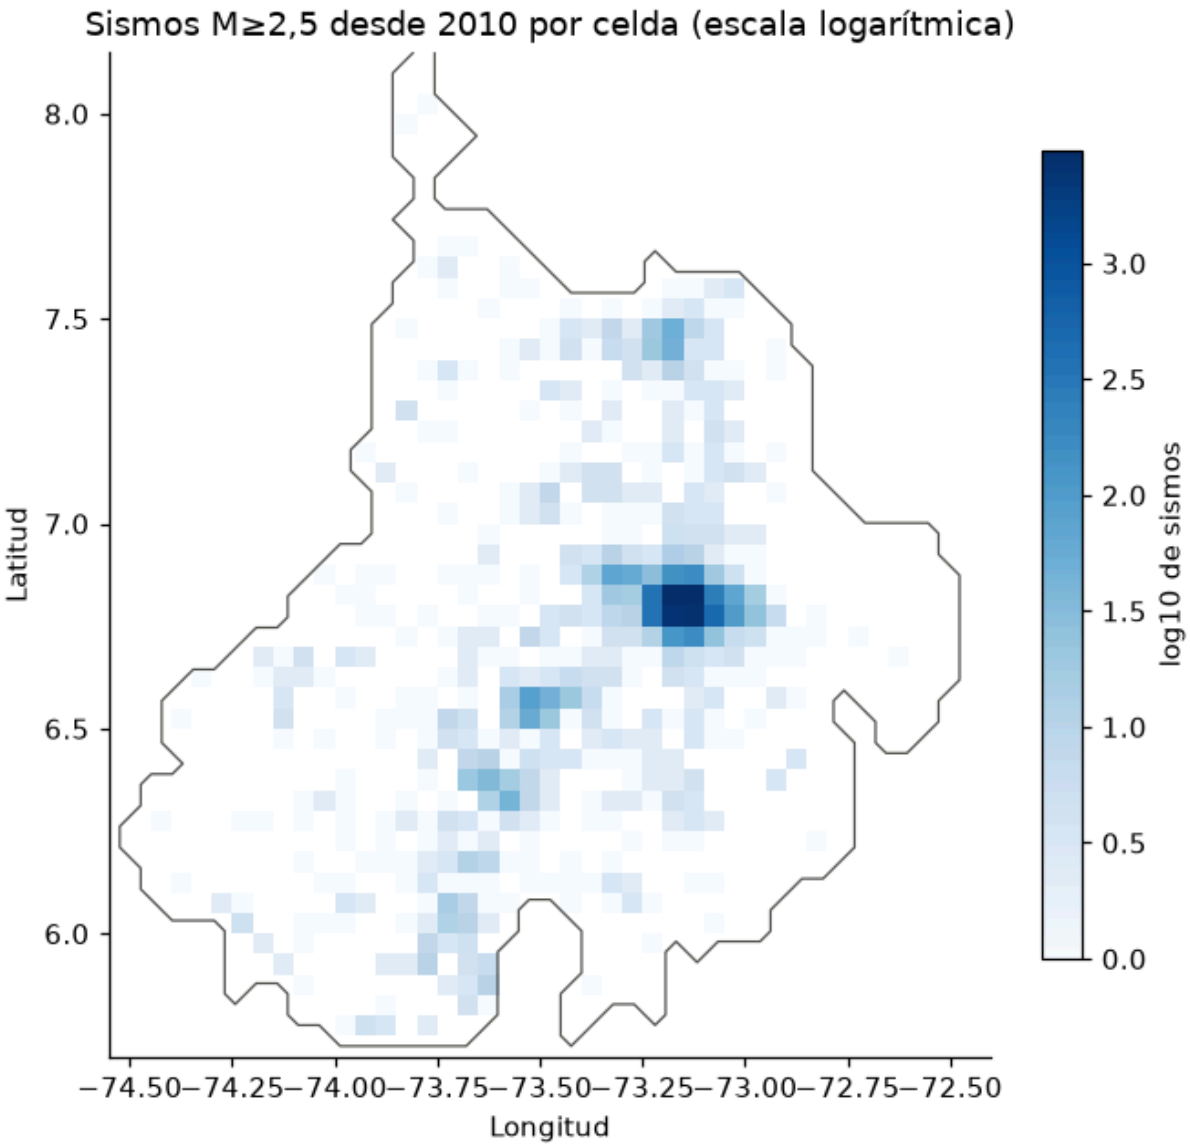
1. Catálogo y grilla

Se usa el catálogo del SGC de todo Santander, ya limpio. La grilla cubre el rectángulo que contiene al departamento, con celdas de 0,05° alineadas con las de Los Santos; solo se modelan las celdas cuyo centro cae dentro del departamento y que tuvieron sismos en el periodo de entrenamiento.

In [2]:
```
cat = catalogo.cargar_catalogo()
homogeneo, grilla = santander.configurar()
n_ventanas = int(homogeneo["ventana"].max()) + 1
print(f"Catálogo limpio: {len(cat):,} sismos  ·  Magnitud {clasificador.MAGNITUD_MI
print(f"Grilla: {clasificador.N_FILAS} x {clasificador.N_COLUMNAS} = {len(grilla):,
print(f"Trimestres completos: {n_ventanas} ({clasificador.etiqueta_de_ventana(0)} a
```

```
Catálogo limpio: 184,723 sismos  ·  Magnitud 2.5 o mayor desde 2010, en la grilla: 1
5,369
Grilla: 49 x 43 = 2,107 celdas en el rectángulo  ·  Dentro de Santander: 997
Trimestres completos: 67 (2010-T1 a 2026-T3)
```

In [3]:
```
variables = clasificador.calcular_variables(homogeneo, grilla, n_ventanas)
total = variables["sismos_trimestre"].sum(axis=2)
permitida = np.isin(grilla["cell_id"].to_numpy(), clasificador.CELDAS_PERMITIDAS.to
fig, eje = plt.subplots(figsize=(6.5, 6.5))
extension = (santander.LON_MIN, santander.LON_MIN + santander.N_COLUMNAS * clasific
imagen = eje.imshow(np.where(permitida & (total > 0), np.log10(np.maximum(total, 1)
eje.contour(permitida.astype(float), levels=[0.5], colors="#52514e", linewidths=0.8
eje.set(title="Sismos M≥2,5 desde 2010 por celda (escala logarítmica)", xlabel="Lon
fig.colorbar(imagen, ax=eje, fraction=0.04, label="log10 de sismos"); plt.show()
ordenado = np.sort(total[permitida])[::-1]
print(f"Celdas de Santander con algún sismo: {(ordenado > 0).sum()} de {permitida.s
print(f"Las 30 celdas más activas concentran el {ordenado[:30].sum() / ordenado.sum
```




```
Celdas de Santander con algún sismo: 443 de 997
Las 30 celdas más activas concentran el 93% de los sismos del departamento
```

Qué se observa. La sismicidad de Santander está muy concentrada: unas pocas celdas del nido acumulan casi todos los sismos y el resto del departamento tiene muy pocos. Eso condiciona todo el modelo.

2. Conjunto de datos

Una fila por celda y trimestre, con las mismas 15 variables del modelo 1 y la misma etiqueta: Bajo (ningún sismo en el trimestre siguiente), Medio (de 1 a 3) y Alto (más de 3).

In [4]:
```
santander.preparar_datos(homogeneo, grilla)
dataset = pd.read_csv(clasificador.DATASET_CSV)
print()
print("Valores faltantes:", int(dataset[clasificador.FEATURES + ["nivel_riesgo"]].i
      " · Filas repetidas (misma celda y trimestre):", int(dataset.duplicated(["cel
```

```
display(dataset.head(6))
display(dataset[clasificador.FEATURES].describe().T[["count", "mean", "std", "min",
```

```
CLASIFICADOR DE RIESGO SÍSMICO POR ZONA - TODO SANTANDER · solo datos
   -> Sismos M>=2.5 desde 2010: 15,369
   -> Celdas en el rectángulo: 2,107   Dentro de Santander: 997   Con sismos en el e
ntrenamiento: 358
   -> Casos (celda, trimestre): 22,554 con 15 variables
   -> Entrenamiento 15,752 casos  Bajo 14,446 (92%)  Medio 1,046 (7%)  Alto 260 (2%)
   -> Prueba         6,802 casos  Bajo 6,237 (92%)  Medio 431 (6%)  Alto 134 (2%)
   -> Conjunto de datos: C:\Users\Santiago\Documents\HACKATON UTS\entrenamiento\2_si
smos_santander\data\processed\dataset_entrenamiento_santander.csv

Valores faltantes: 0  · Filas repetidas (misma celda y trimestre): 0
```

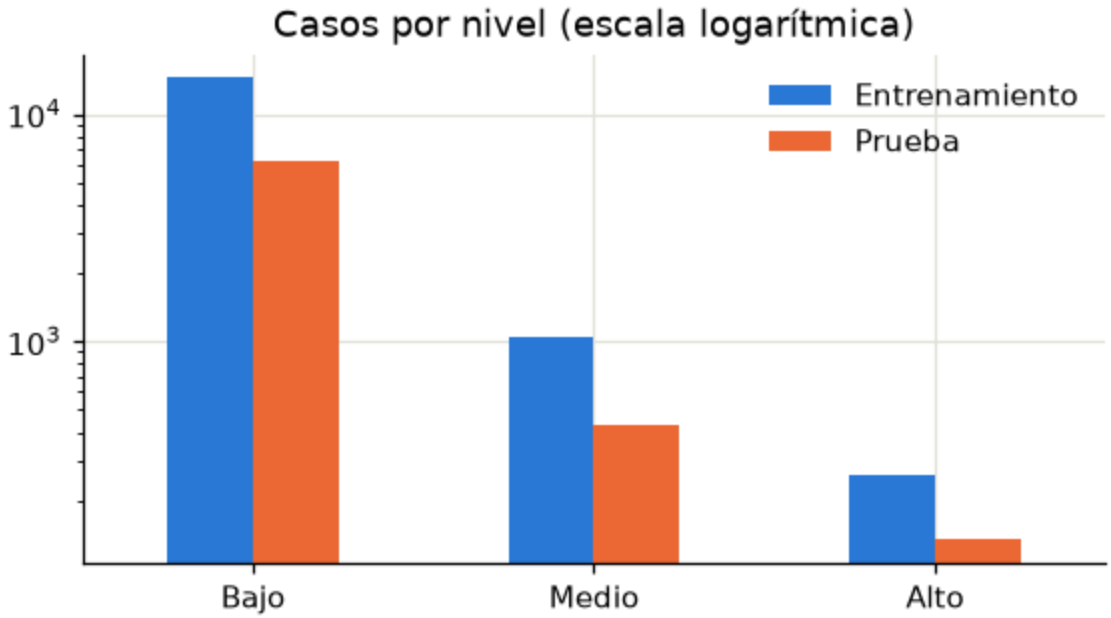
	cell_id	sismos_trimestre	sismos_ultimo_anio	sismos_promedio_historico	tendencia_sismos
0	54	0.000	0.000	0.000	0.000
1	55	0.000	0.000	0.000	0.000
2	56	0.000	0.000	0.000	0.000
3	58	0.000	0.000	0.000	0.000
4	103	0.000	1.000	0.250	-0.250
5	145	0.000	0.000	0.000	0.000

	count	mean	std	min	50%	max
sismos_trimestre	22,554.000	0.636	5.820	0.000	0.000	141.000
sismos_ultimo_anio	22,554.000	2.550	22.315	0.000	0.000	435.000
sismos_promedio_historico	22,554.000	0.621	4.516	0.000	0.034	64.659
tendencia_sismos	22,554.000	-0.001	1.720	-49.000	0.000	52.500
sismos_vecinos_ultimo_anio	22,554.000	19.939	91.164	0.000	1.000	914.000
mag_media_ultimo_anio	22,554.000	0.604	1.193	0.000	0.000	5.000
mag_max_ultimo_anio	22,554.000	0.652	1.309	0.000	0.000	6.400
log_energia_ultimo_anio	22,554.000	1.996	3.928	0.000	0.000	14.400
prop_moderados_ultimo_anio	22,554.000	0.024	0.136	0.000	0.000	1.000
trimestres_desde_sismo_fuerte	22,554.000	61.920	15.794	0.000	67.000	67.000
prof_media_ultimo_anio	22,554.000	24.204	50.858	-1.000	0.000	211.000
prof_std_ultimo_anio	22,554.000	0.319	2.491	0.000	0.000	94.500
dist_nido_km	22,554.000	62.089	34.079	3.758	59.108	154.538
lat_center	22,554.000	6.689	0.451	5.775	6.675	7.675
lon_center	22,554.000	-73.434	0.335	-74.375	-73.375	-72.625

In [5]:
```
es_prueba = dataset["trimestre_objetivo"] >= "2022-T1"
reparto = pd.DataFrame({"Entrenamiento": dataset[~es_prueba]["nivel_riesgo"].value_
                        "Prueba": dataset[es_prueba]["nivel_riesgo"].value_counts()
porcentajes = (100 * reparto / reparto.sum()).round(1).add_suffix(" %")
display(pd.concat([reparto, porcentajes], axis=1))
print(f"Entrenamiento: {dataset[~es_prueba]['trimestre_objetivo'].min()} a {dataset
      f"   Prueba: {dataset[es_prueba]['trimestre_objetivo'].min()} a {dataset[es_p
fig, eje = plt.subplots(figsize=(6, 3))
reparto.plot.bar(ax=eje, color=[AZUL, NARANJA], rot=0, logy=True); eje.set(title="C
```

	Entrenamiento	Prueba	Entrenamiento %	Prueba %
nivel_riesgo				
Bajo	14446	6237	91.700	91.700
Medio	1046	431	6.600	6.300
Alto	260	134	1.700	2.000

```
Entrenamiento: 2011-T1 a 2021-T4   Prueba: 2022-T1 a 2026-T3
```



Lo que hay que tener presente al entrenar. Más del 90 % de los casos son de nivel Bajo. Un modelo que dijera siempre «Bajo» acertaría más del 90 %, así que **la exactitud no sirve para juzgar este modelo**: habrá que mirar el F1 macro y el recall de los niveles Medio y Alto, y compararlo con la regla de persistencia.

3. Entrenamiento

Se ejecuta el mismo proceso del modelo 1, con la grilla de Santander. Los ajustes del Random Forest (balanceo de clases y profundidad) se eligen con validación dentro del periodo de entrenamiento (2017 a 2021), sin mirar la prueba. Lo que sigue es la salida completa del script.

In [6]:
```
clasificador.main()
```

```
================================================================================
CLASIFICADOR DE RIESGO SÍSMICO POR ZONA - TODO SANTANDER
================================================================================

1. Carga y limpieza del catálogo del SGC...
   -> Sismos en el catálogo:                 184,723
   -> Sismos M>=2.5 desde 2010 (homogéneo):   15,369 (15,369 en la zona y el resto e
n su margen)
   -> Trimestres completos: 67 (2010-T1 a 2026-T3)

2. Grilla e ingeniería de variables...
```

```
   -> Celdas de 0.05°: 2107 en la grilla, 358 con sismicidad
   -> Muestras (celda, trimestre): 22,554 con 15 variables

3. Etiqueta: nivel de actividad del trimestre siguiente...
   -> Bajo:  hasta 0 sismos M>=2.5 en el trimestre
   -> Medio: más de 0 y hasta 3
   -> Alto:  más de 3
   -> Entrenamiento 2011-T1 a 2021-T4: 15752 muestras  Bajo 14446  Medio 1046  Alto
260
   -> Prueba        2022-T1 a 2026-T3: 6802 muestras  Bajo 6237  Medio 431  Alto 134

4. Entrenamiento y evaluación en el periodo de prueba...
   -> Ajustes del Random Forest elegidos con validación interna (2017 a 2021): balan
ceo 0.5, profundidad 10
      balanceo 0.50  profundidad 10  ->  F1 macro 71.29%  exactitud 92.99%
      balanceo 0.75  profundidad  6  ->  F1 macro 70.60%  exactitud 91.72%
      balanceo 0.75  profundidad 10  ->  F1 macro 70.55%  exactitud 91.59%
      balanceo 0.50  profundidad  6  ->  F1 macro 70.42%  exactitud 92.97%
```

```
================================================================================
RESULTADOS EN EL PERIODO DE PRUEBA
================================================================================
Modelo                                 Accuracy  F1 macro  Recall Alto
Base: clase más frecuente                91.69%    31.89%        0.00%
Base: igual al trimestre anterior        90.86%    70.00%       86.57%
Base: promedio del último año            82.99%    68.23%       93.28%
Regresión Logística                      84.11%    68.37%       97.76%
Random Forest                            93.44%    74.29%       89.55%

   -> Modelo elegido: Random Forest

   -> Techo de referencia (oráculo que conoce la tasa real de cada celda):
      Accuracy 94.16%, F1 macro 73.55%
      El modelo alcanza el 99% de esa exactitud; el error restante es sobre todo aza
r de los sismos.

REPORTE DE CLASIFICACIÓN (Random Forest):
              precision    recall  f1-score   support

        Bajo     0.9603    0.9743    0.9673      6237
       Medio     0.4938    0.3689    0.4223       431
        Alto     0.7895    0.8955    0.8392       134

    accuracy                         0.9344      6802
   macro avg     0.7479    0.7463    0.7429      6802
weighted avg     0.9274    0.9344    0.9302      6802

MATRIZ DE CONFUSIÓN (Filas: Real, Columnas: Predicho):
            Pred_Bajo  Pred_Medio  Pred_Alto
Real_Bajo        6077         151          9
Real_Medio        249         159         23
Real_Alto           2          12        120

IMPORTANCIA DE LAS VARIABLES (Random Forest):
    1. sismos_ultimo_anio              : 16.50% ██████
    2. sismos_vecinos_ultimo_anio      : 14.99% ████
    3. sismos_promedio_historico       : 13.84% ████
    4. dist_nido_km                    : 13.60% ████
    5. prof_std_ultimo_anio            :  8.09% ███
    6. sismos_trimestre                :  7.22% ██
    7. log_energia_ultimo_anio         :  5.40% ██
    8. prof_media_ultimo_anio          :  4.82% ██
    9. mag_max_ultimo_anio             :  4.13% ██
   10. prop_moderados_ultimo_anio      :  2.79% ██
   11. trimestres_desde_sismo_fuerte   :  2.33%
   12. lon_center                      :  2.00%
   13. mag_media_ultimo_anio           :  1.68%
   14. lat_center                      :  1.63%
   15. tendencia_sismos                :  0.98%

5. Modelo final con todos los datos y predicción del próximo trimestre...
```

```
   -> Riesgo predicho para 2026-T4: 2082 celdas en Bajo, 19 celdas en Medio, 6 celda
s en Alto
   -> Dataset de entrenamiento: C:\Users\Santiago\Documents\HACKATON UTS\entrenamien
to\2_sismos_santander\data\processed\dataset_entrenamiento_santander.csv
   -> Grilla con el riesgo:     C:\Users\Santiago\Documents\HACKATON UTS\entrenamien
to\2_sismos_santander\data\processed\grilla_riesgo_santander.geojson
   -> Modelo:                   C:\Users\Santiago\Documents\HACKATON UTS\entrenamien
to\2_sismos_santander\models\modelo_riesgo_sismico_santander.pkl
   -> Métricas:                 C:\Users\Santiago\Documents\HACKATON UTS\entrenamien
to\2_sismos_santander\models\metricas_clasificador_santander.json
   -> Historial de la prueba:   C:\Users\Santiago\Documents\HACKATON UTS\entrenamien
to\2_sismos_santander\models\historial_prueba_santander.json
================================================================================
PIPELINE COMPLETADO.
================================================================================
```

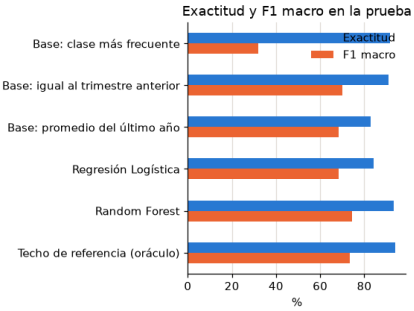
4. Resultados en el periodo de prueba

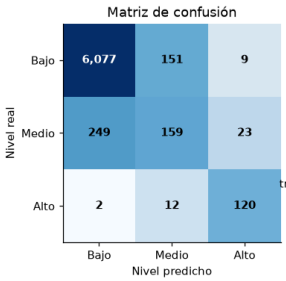
In [7]:
```
guardado = json.loads(clasificador.METRICAS_JSON.read_text(encoding="utf-8"))
resultados = pd.DataFrame(guardado["metricas"]).T
resultados.loc["Techo de referencia (oráculo)"] = guardado["techo_del_problema"]
display((100 * resultados).round(2).rename(columns={"accuracy": "Exactitud %", "f1_
print("Modelo elegido:", guardado["modelo_elegido"], "· Ajustes:", {k: v for k, v i
print(f"Casos de prueba: {guardado['muestras_prueba']:,} ({guardado['periodo_prueba

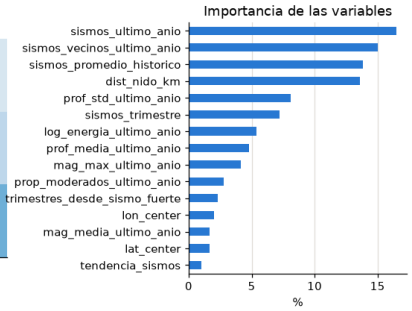
matriz = np.array(guardado["matriz_confusion"]["valores"])
importancias = pd.Series(guardado["importancia_variables"]).sort_values()
fig, ejes = plt.subplots(1, 3, figsize=(15, 4))
(100 * resultados[["accuracy", "f1_macro"]]).plot.barh(ax=ejes[0], color=[AZUL, NAR
ejes[0].set(title="Exactitud y F1 macro en la prueba", xlabel="%"); ejes[0].legend(
ejes[1].imshow(np.log10(matriz + 1), cmap="Blues"); ejes[1].grid(False)
ejes[1].set(title="Matriz de confusión", xlabel="Nivel predicho", ylabel="Nivel rea
            xticklabels=clasificador.NIVELES, yticklabels=clasificador.NIVELES)
for a in range(3):
    for b in range(3):
        ejes[1].text(b, a, f"{matriz[a, b]:,}", ha="center", va="center", color="wh
(100 * importancias).plot.barh(ax=ejes[2], color=AZUL); ejes[2].set(title="Importan
plt.tight_layout(); plt.show()
```

	Exactitud %	F1 macro %	Recall del nivel Alto %
Base: clase más frecuente	91.690	31.890	0.000
Base: igual al trimestre anterior	90.860	70.000	86.570
Base: promedio del último año	82.990	68.230	93.280
Regresión Logística	84.110	68.370	97.760
Random Forest	93.440	74.290	89.550
Techo de referencia (oráculo)	94.160	73.550	91.790

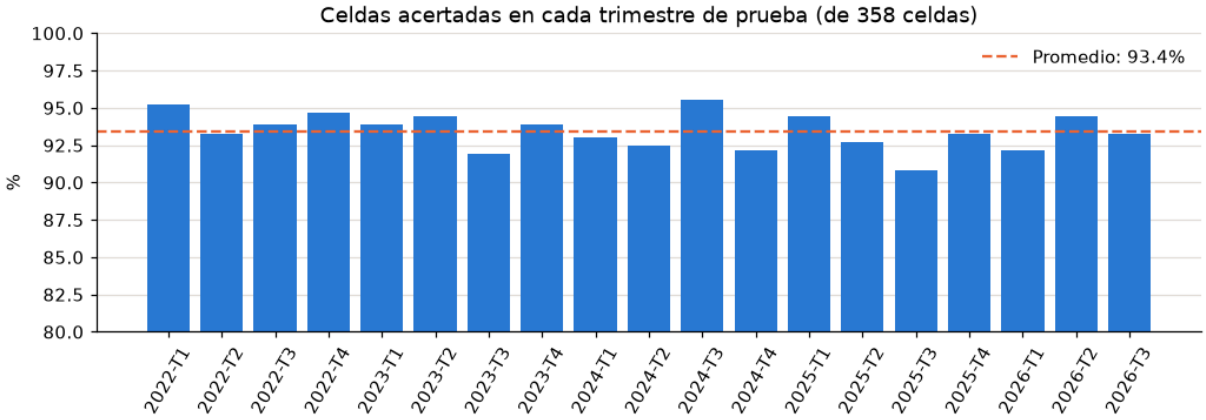
```
Modelo elegido: Random Forest · Ajustes: {'balanceo': 0.5, 'profundidad': 10}
Casos de prueba: 6,802 (2022-T1 a 2026-T3)
```







In [8]:
```
historial = json.loads(clasificador.HISTORIAL_JSON.read_text(encoding="utf-8"))
con_modelo = historial["celdas_con_modelo"]
aciertos = pd.Series({t["trimestre"]: sum(t["predicho"][c] == t["real"][c] for c in
fig, eje = plt.subplots(figsize=(11, 3))
eje.bar(aciertos.index, 100 * aciertos / len(con_modelo), color=AZUL)
eje.axhline(100 * aciertos.mean() / len(con_modelo), color=NARANJA, linestyle="--",
eje.set(title=f"Celdas acertadas en cada trimestre de prueba (de {len(con_modelo)}
eje.grid(axis="x", visible=False); eje.legend(frameon=False); plt.show()
```



Cómo leer estos resultados.

- **La exactitud es alta, pero engaña:** decir siempre «Bajo» ya acierta cerca del 92 %. Lo que importa es el **F1 macro**, que pesa por igual los tres niveles, y el recall del nivel Alto.
- **El Random Forest supera a la regla de persistencia** («igual al trimestre anterior») tanto en exactitud como en F1 macro.
- **El nivel Medio es el más difícil**, igual que en el modelo 1: las celdas con uno a tres sismos por trimestre son las más sujetas al azar.
- **Este modelo no sustituye al de Los Santos.** Para esas 30 celdas predice mejor el modelo 1, entrenado solo con ellas.